

Estado da Arte (2020–2026) sobre Governança, Detecção e Mitigação de Conflitos Multi-xApp em O-RAN

Evidências para as hipóteses do XApp-RDL-F1 (H-RDL), lacunas científicas e comparação sistemática

Síntese técnica para o projeto XApp-RDL-F1

27 de setembro de 2026

Resumo

Este documento realiza uma revisão aprofundada da literatura entre 2020 e setembro de 2026 sobre coordenação, detecção, classificação, avaliação e mitigação de conflitos entre xApps no Near-RT RIC. A análise é orientada pelas hipóteses científicas do XApp-RDL-F1 (H-RDL): (H1) redução de violações de SLA com preservação de justiça; (H2) supressão de oscilações temporais e *ping-pong*; (H3) overhead algorítmico sub-milissegundo; e (H4) otimização segura por Safe-MAPPO com bloqueio de ações inseguras. São cobertos trabalhos seminais sobre O-RAN programável e controle fechado, coordenação multiagente, frameworks formais de *Conflict Mitigation*, barganha/game theory, QoS-aware conflict management, profiling pré-deployment, grafos de conflito, Digital Twins, escalonadores adaptativos, validação OTA, knowledge/policy distillation e métodos AI-native/LLM de 2026. A revisão evidencia que a literatura converge para a necessidade de uma camada explícita de governança entre xApps, mas ainda apresenta fragmentação entre segurança determinística, baixa latência, conflitos temporais, interoperabilidade E2 e adaptação aprendida. Esse espaço é precisamente o nicho científico da arquitetura H-RDL/CA-RDL.

1 Escopo, método de busca e critérios

A busca foi orientada a trabalhos publicados ou disponibilizados entre 2020 e 27 de setembro de 2026, com ênfase em IEEE, ACM, Elsevier/Computer Networks, Springer, ITU Journal, MDPI e preprints arXiv quando ainda não havia publicação final identificada. Foram combinados grupos de consulta envolvendo: *O-RAN*, *xApp*, *Near-RT RIC*, *conflict mitigation*, *conflict management*, *multi-xApp*, *team learning*, *game theory*, *QoS-aware*, *traffic steering*, *energy saving*, *resource/power allocation*, *GNN conflict graph*, *digital twin*, *scheduler*, *OTA testbed*, *safe reinforcement learning*, *policy distillation*, *AI-native* e *generative agents*.

Foram incluídos trabalhos que satisfazem pelo menos um dos seguintes critérios:

- (i) estabelecem a arquitetura de controle fechado e execução de xApps;
- (ii) identificam o risco de ações concorrentes ou objetivos antagônicos;
- (iii) propõem coordenação ou mitigação de conflitos;
- (iv) avaliam efeitos em QoS, throughput, energia, estabilidade, handover ou SLA;
- (v) medem latência/viabilidade de execução dentro da janela do Near-RT RIC;
- (vi) tratam segurança, restrições, explicabilidade ou prevenção de ações inseguras.

A presente revisão é **exaustiva no eixo temático selecionado**, mas não deve ser denominada revisão sistemática PRISMA sem uma etapa adicional de deduplicação bibliométrica formal, contagem de registros por base e registro de protocolo.

2 Hipóteses do XApp-RDL-F1 utilizadas como eixo de comparação

A documentação atual do XApp-RDL-F1 estabelece as seguintes hipóteses:

H1 – SLA e justiça.

A H-RDL reduz a taxa de violação de SLA em pelo menos 30 pontos percentuais contra o baseline não coordenado, preservando *Jain* $\geq 0,90$.

H2 – Estabilidade temporal.

A H-RDL reduz *Action Churn* para menos de 0,1 ação/s e atinge $t_{\text{settle}} < 200$ ms em cenário de *ping-pong*.

H3 – Overhead.

O tempo algorítmico de decisão é sub-milissegundo, $T_{\text{decision}} < 1$ ms.

H4 – Segurança aprendida.

Safe-MAPPO produz ganho de utilidade mantendo $UnsafeApplied \equiv 0$.

O projeto posiciona a H-RDL como uma camada intermediária de governança no Near-RT RIC: intercepta propostas concorrentes, detecta conflitos, arbitra ações, aplica *Safety Guards* físicos e somente então emite controle E2SM-RC. A fase CA-RDL acrescenta contexto, grafo de conhecimento e Safe-MAPPO.

3 Evolução do estado da arte: 2020–2026

3.1 2020–2021: programabilidade, closed-loop e nascimento do problema de coordenação

Bonati et al. apresentam a O-RAN como plataforma para *closed-control loops* programáveis e controle de RAN por xApps no Near-RT RIC [1]. Essa base é essencial para o problema estudado no XApp-RDL: uma vez que múltiplos controladores independentes podem atuar sobre o mesmo ambiente, passa a existir acoplamento entre políticas e objetivos.

Rivera et al. propõem *multi-agent team learning* para a coordenação dos controladores O-RAN, explicitando que a desagregação e virtualização tornam inadequadas várias soluções clássicas de SON [2]. O trabalho é particularmente importante porque antecipa o ponto central da governança multi-xApp: agentes independentes modificam o ambiente percebido pelos demais.

No plano de infraestrutura, FlexRIC demonstra uma SDK de RIC com execução de múltiplos xApps e suporte a E2 [3]; CoO-RAN/OpenRAN Gym viabilizam experimentação closed-loop em escala [4, 5]; e Dryjański et al. mostram uma implementação modular de *Traffic Steering* [6]. Esses trabalhos não resolvem a arbitragem multi-xApp, mas fornecem a base arquitetural e experimental na qual conflitos se manifestam.

3.2 2022: primeira coordenação explícita entre xApps conflitantes

Zhang, Zhou e Erol-Kantarci formulam explicitamente o problema de conflitos entre xApps de fornecedores distintos e propõem *team learning* [7]. O caso combina alocação de potência e recursos; os agentes compartilham informação para reduzir interferência mútua. O resultado reportado de maior throughput e menor PDR fornece evidência direta para H1: coordenação entre aplicações concorrentes supera execução independente.

Kouchaki e Marojevic mostram o desenho e implantação de um xApp de alocação de recursos baseado em actor-critic, reforçando a viabilidade de políticas aprendidas no Near-RT RIC, mas também evidenciando a necessidade de um caminho end-to-end reproduzível para controlar ações de ML [8].

3.3 2023: formalização da taxonomia, CMF e arbitragem explícita

Adamczyk e Kliks propõem um *Conflict Mitigation Framework* (CMF) integrado ao Near-RT RIC, com detecção dos tipos direto, indireto e implícito definidos pela O-RAN [9]. Esse trabalho é um dos antecedentes mais próximos da H-RDL: insere uma função central que recebe decisões de xApps, detecta conflitos e resolve antes/ao redor da atuação na RAN.

Wadud, Golpayegani e Afraz introduzem um sistema de conflito com controladores de detecção/mitigação e aplicam barganha cooperativa, incluindo Nash Social Welfare e solução Eisenberg–Gale [10]. A proximidade com a H-RDL é forte na ideia de arbitragem explícita e balanceamento entre interesses, mas o trabalho é majoritariamente teórico e não combina a barganha com uma camada separada de invariantes físicos determinísticos.

3.4 2024: QoS-aware, profiling, conflitos convergentes e grafos

QACM evolui o eixo de game theory para maximizar o número de xApps que mantêm seus requisitos de QoS [11]. É uma evidência particularmente forte para H1: o critério de resolução não deve ser apenas prioridade estática, mas preservação mensurável de requisitos de serviço.

PACIFISTA introduz avaliação e gerenciamento preventivo via profiling em sandbox, grafos hierárquicos e modelos estatísticos [12]. Os experimentos indicam degradação relevante mesmo quando aplicações possuem objetivos semelhantes, e instabilidade ainda maior quando objetivos são antagônicos. Esse achado sustenta o baseline B0 da H-RDL e a premissa de que coexistência sem governança é insuficiente.

Corici et al. argumentam que o isolamento individual de funções não é suficiente e que decisões conflitantes causam instabilidade, propondo um framework de gerenciamento para o plano de controle convergente 6G [13]. A contribuição reforça H2, pois estabilidade temporal passa a ser propriedade explícita do plano de controle, não apenas um KPI de uma xApp isolada.

Zolghadr et al. mostram que soluções anteriores assumem conflitos conhecidos a priori e propõem GraphSAGE para reconstruir relações escondidas entre xApp, parâmetros e KPIs [14]. Essa linha é diretamente relacionada à fase CA-RDL e à RQ5 do projeto.

3.5 2025: NDT, scheduler, testbed OTA, causalidade e produção

COMIX combina CMF com Network Digital Twin para avaliar ações concorrentes antes da aplicação na rede, em cenário de potência versus eficiência energética [15]. O princípio “avaliar antes de atuar” converge com o *Safety Guard* da H-RDL, embora COMIX use NDT e resolução baseada em políticas de conflito.

Cinemre e Mahmoodi propõem um *scheduler* adaptativo baseado em A2C, capaz de escolher entre xApps sem re-treiná-las conjuntamente [16]. O trabalho evidencia que conflito é dependente de contexto: duas aplicações podem coexistir em um estado e entrar em conflito em outro. Isso sustenta a evolução H-RDL→CA-RDL.

Sultana et al. validam CMF em testbed O-RAN OTIC com RF OTA, reportando forte redução da variabilidade de throughput [17]. É uma peça importante para H2: mitigação reduz instabilidade observada em ambiente real, não apenas em simulação.

Sharma et al. propõem avaliação de conflitos com SHAP e inferência causal (ATE/CATE), criando um DAG entre RAN Control Parameters e KPIs [18]. A relação com a H-RDL está na necessidade de explicar conflitos indiretos e separar correlação de efeito causal.

3.6 2026: distillation, AI-native, escalabilidade, agentes generativos e interoperabilidade

Erdol et al. propõem *xApp distillation*, consolidando conhecimento de múltiplas xApps conflitantes em um único modelo [19]. A abordagem reduz interrupções e evita descartar informação, mas muda a unidade de governança: em vez de arbitrar aplicações independentes em runtime, cria uma política agregada. A H-RDL preserva independência de xApps e aplica governança externa, o que é vantajoso quando modelos são de terceiros/caixas-pretas.

Wadud et al. apresentam framework AI-powered com GNN/Bi-LSTM/SMOTE para detecção e classificação em cenários de 5–50 xApps, reportando classificação mais rápida que regras em larga escala [20]. Isso expõe um trade-off importante: regras são adequadas para pequeno conjunto de relações conhecidas; aprendizagem se torna atraente para escalabilidade e relações ocultas. A arquitetura em fases H-RDL/CA-RDL é coerente com essa evidência.

ORIGAMI demonstra mediação entre xAppde energia e xAppde throughput em testbed distribuído, via arquitetura orientada a serviços [21]. É um paralelo direto com o cenário EEVS da H-RDL.

Salmi et al. propõem arquitetura AI-native com motor de conflito no Near-RT RICe orquestração de intenção no Non-RT RIC [22]; Kurtulan et al. apresentam um orquestrador ML-driven multi-xApp[23]; e Kwon e Zhang exploram agentes generativos com RAG e raciocínio simbólico para conflito sob incerteza [24]. Esses trabalhos mostram que o campo migra de simples prioridade para governança adaptativa e semântica.

Obiuevewi et al. medem inferência e latência de serviço de IA dentro de um xAppem testbed OAI/FlexRIC, com execução tipicamente dentro de poucos milissegundos [25]. Essa evidência dá suporte independente a H3: há margem computacional significativa dentro do envelope temporal do Near-RT RIC, tornando plausível uma arbitragem determinística sub-ms.

4 Recortes da literatura que sustentam diretamente as hipóteses

Os trechos abaixo são deliberadamente curtos e usados apenas como evidência textual de formulações centrais dos trabalhos.

4.1 H1 – Coordenação reduz degradação de QoS/SLA

Zhang et al. (2022): “this may lead to conflicts in network function implementations”; o trabalho reporta melhoria com *team learning* sobre agentes independentes [7].

PACIFISTA: “users can experience a 16% throughput loss” mesmo com xApps de objetivos semelhantes; objetivos conflitantes chegam a degradação maior [12].

QACM: busca “maximizing the number of xApps that have their QoS requirements met” [11].

OTIC 2025: o CMF reduziu a variabilidade observada de throughput DL em 78% no testbed [17].

Leitura para H1. Esses resultados não provam os limiares específicos do XApp-RDL (-30 p.p. em SLA e $J \geq 0,90$), mas estabelecem a premissa causal externa: **coordenação explícita melhora QoS/estabilidade em relação a xApps independentes**. Os limiares quantitativos de H1 permanecem uma contribuição empírica própria do XApp-RDL.

4.2 H2 – Conflitos produzem instabilidade; governança reduz oscilação

Corici et al. (2024): “the complete isolation of these xApps would result in conflicting decisions and instability” [13].

Wadud et al. (2026): ajustes independentes de parâmetros podem “lead to network instability and KPI degradation” [20].

OTIC 2025: a mitigação produziu “significant improvement in network operation stability” [17].

Leitura para H2. A literatura sustenta fortemente o mecanismo causal de H2, porém quase não padroniza *Action Churn*, *cooldown* e t_{settle} como métricas centrais. Essa é uma oportunidade de originalidade: tratar conflito temporal como fenômeno de controle dinâmico e demonstrar supressão quantitativa de *ping-pong*.

4.3 H3 – É factível arbitrar dentro do envelope Near-RT

xApp Distillation: o Near-RT RICopera em “10 milliseconds to 1-second control loops” [19].

FlexRIC: latência de monitoramento em hardware moderno é descrita como inferior a $200 \mu\text{s}$ em sua implementação de referência [3].

Obiuwevwi et al. (2026): inferências leves ficam em microssegundos e serviço end-to-end típico em poucos milissegundos [25].

Leitura para H3. A literatura torna *plausível* $T_{\text{decision}} < 1$ ms para uma arbitragem determinística leve. Ainda assim, o valor de $0,12$ ms deve ser reportado como **medição própria** com hardware, carga, linguagem, número de propostas e percentis claramente especificados.

4.4 H4 – Segurança explícita é necessária ao usar aprendizado

Safe RAN Slicing (2026): RL convencional pode sofrer com “unsafe exploration behavior”, resultando em violações de SLA [26].

COMIX: utiliza NDT para avaliar impacto de ações conflitantes *antes* de aplicá-las à rede [15].

Z²-ACT (2026): loops AI-assisted devem permanecer “safe, verifiable, and auditable” sob intenções concorrentes [27].

Leitura para H4. A evidência externa apoia a necessidade de proteção. O diferencial do XApp-RDL é a **separação arquitetural** entre a política aprendida e um *Safety Guard* determinístico fora da rede neural. Essa separação deve ser explorada como contribuição: mesmo quando a política erra, a barreira de segurança impede a atuação inválida.

5 Tabela comparativa do estado da arte e posicionamento do XApp-RDL

Tabela 1: Comparação entre trabalhos relacionados (2020–2026) e XApp-RDL.

Trabalho	Ano	Problema/Conflito	Método	Tipos de conflito	Validação	Segurança explícita	ex- de controle	Latência/tempo de controle	Relação com XApp-RDL
Rivera et al. [2]	2020	Coordenação de agentes em O-RAN	Multi-agent team learning	Implícito/objetivos acoplados	Estudo/caso	Não		Não central	Antecede CA-RDL; não oferece guard determinístico.
Bonati et al. [1]	2021	Closed-loop e IA no RIC	DRL/data-driven O-RAN	Não foca CM	Colosseum	Não		Near-RT	Base arquitetural para RDL.
FlexRIC [3]	2021	Execução programável multi-xApp	SDK Near-RT RIC/E2	Não foca CM	Implementação real	Não	μ s em caminho monitorado		Sustenta viabilidade H3/interoperabilidade.
Dryjański et al. [6]	2021	Traffic Steering modular	xApp TS hierárquica	Potencial conflito de mobilidade	Implementação modular	Não		Near-RT	xApp de referência para cenário TVS/TS.
Zhang et al. [7]	2022	Power vs resource allocation	Cooperative/team DRL	Principalmente indireto	Simulação	Parcial		Não central	Evidência H1; exige co-operação entre xApps.
Kouchaki & Marojevic [8]	2022	Resource allocation	Actor-critic xApp	Não foca multi-xApp	Design/deploy	Não		Near-RT	Base para política aprendida; não governa concorrência.
Adamczyk & Kliks [9]	2023	Conflitos intra-RIC	CMF + detecção dedicada	Direto, indireto, implícito	Simulação	Parcial		Near-RT	Um dos mais próximos; H-RDL acrescenta guard físico e temporalidade.
Wadud et al. [10]	2023	Configuração de parâmetros conflitantes	Barganha/NSWF/EG	Direto/indireto	Cenário teórico	Não		Não central	Forte relação com arbitragem Nash da H-RDL.
QACM [11]	2024	Preservação de QoS multi-xApp	Otimização QoS-aware	Direto, indireto, implícito	Casos simulados	Parcial		Não central	Sustenta H1; H-RDL enfatiza invariantes e baixa latência.
Corici et al. [13]	2024	Instabilidade do plano de controle	Framework convergente	Multi-loop	Arquitetura/roadmap	Parcial		Near-RT	Sustenta H2 e governança central.
PACIFISTA [12]	2024/25	Predição de conflitos pré-deployment	Profiling + grafos + estatística	Direto/indireto/implícito	Colosseum/OpenRAN Gym	Parcial		Offline/pre-deploy + runtime	Complementar: previne deployment; H-RDL arbitra runtime.
Zolghadr et al. [14]	2024/25	Relações ocultas parâmetro-KPI	GraphSAGE	Direto/indireto/implícito	Modelo numérico/WCNC	Não		Não central	Antecedente direto do KG/GNN da CA-RDL.
COMIX [15]	2025	Throughput vs energia/potência	CMF + NDT	Direto/indireto	Cenário multicanal	Parcial		Avaliação pré-ação	Muito próximo do EEVS; H-RDL usa guard determinístico mais leve.
Cinemre & Mahmodi [16]	2025	Escolha dinâmica entre xApps	Scheduler A2C	Indireto/contextual	Simulação	Não		Near-RT conceitual	Sustenta contexto; próximo à evolução CA-RDL.
Sultana et al. [17]	2025	CMF em ambiente real	Detecção + resolução	Caso indireto/priorização	OTIC + OTA RF	Parcial		Runtime	Evidência externa forte para H2.
Sharma et al. [18]	2025	Descoberta/quantificação causal	SHAP + DAG + ATE/CATE	Indireto/implícito	Dados/modelagem	Não		Não central	Complementa cadeia causal da RDL.
xApp Distillation [19]	2026	Eliminar conflitos entre políticas	Policy distillation	Multi-xApp	Simulação	Parcial		Near-RT	Alternativa arquitetural: funde políticas; RDL preserva independência.
Wadud et al. [20]	2026	Escala de 5–50 xApps	GNN/Bi-LSTM/SMOTE	Direto/indireto/implícito	ns3-8-oran + sintético	Não		Classificação acelerada	Mostra limite de regras em escala; motiva CA-RDL.
ORIGAMI [21]	2026	Energia vs throughput	GSBA + mediação	Objetivos antagônicos	Testbed distribuído	Parcial		Runtime	Paralelo direto ao cenário EEVS.

Trabalho	Ano	Problema/Conflito	Método	Tipos de conflito	Validação	Segurança ex-plicita	Latência/tempo de controle	Relação com XApp-RDL
Salmi et al. [22]	2026	Coordenação AI-native + intents	CME adaptativo + LLM Non-RT	Multi-xApp/rApp	Medições/protótipo	Parcial	Near-RT	Direção futura do RDL fase 3.
Kurtulan et al. [23]	2026	Conflitos multi-xApp em 6G	ML orchestrator	Multi-xApp	Experimental	Parcial	Real-time	Próximo à orquestração adaptativa CA-RDL.
ORCA [24]	2026	Conflitos desconhecidos sob incerteza	LLM agents + RAG + simbólico	Implícito/desconhecido	INFOCOM	Parcial	Não foco principal	Complementar para raciocínio semântico futuro.
XApp-RDL F1/F2	2026	QoS, slicing, energia, TS, temporalidade e safety	Arbitragem hierárquica + Nash/heurística + hard guards; KG/GNN + Safe-MAPPO	Direto, implícito/temporal	ns-3/5G-LENA/NORI + E2 closed-loop	Sim: guard de-sacoplado	H-RDL: 0,12 ms reportado; CA-RDL: ms	Integra segurança determinística, governança runtime e evolução cognitiva.

6 Matriz de aderência da literatura às hipóteses H1–H4

Tabela 2: Aderência conceitual dos trabalhos às hipóteses do XApp-RDL. “Forte” significa que o trabalho testa diretamente mecanismo semelhante; não significa validação do limiar numérico do XApp-RDL.

Trabalho	H1	H2	H3	H4
Zhang et al. 2022	Forte	Média	Baixa	Baixa
Adamczyk & Kliks 2023	Forte	Forte	Média	Média
QACM 2024	Forte	Média	Baixa	Média
PACIFISTA 2025	Forte	Forte	Baixa	Média
COMIX 2025	Forte	Média	Média	Forte
Sultana et al. OTIC 2025	Forte	Forte	Média	Média
xApp Distillation 2026	Forte	Forte	Média	Média
AI-powered CM 2026	Forte	Forte	Média	Baixa
ORIGAMI 2026	Forte	Forte	Média	Média
Real-Time AI xApp 2026	Baixa	Baixa	Forte	Baixa
Safe RAN Slicing 2026	Forte	Média	Média	Forte
XApp-RDL	Direta	Direta	Direta	Direta

7 Lacunas identificadas e contribuição científica potencial da H-RDL

7.1 Lacuna 1: segurança determinística desacoplada da política

Grande parte da literatura escolhe uma das seguintes estratégias: prioridade, otimização de utilidade, aprendizado conjunto, NDT, distillation ou classificação AI. Poucos trabalhos separam de forma explícita:

$$\text{Reasoning/Optimization} \rightarrow \boxed{\text{Safety Guard invariável}} \rightarrow \text{E2 actuation.}$$

Esse desacoplamento oferece uma propriedade publicável: **a segurança não depende da convergência, generalização ou calibração da política aprendida.**

7.2 Lacuna 2: conflitos temporais tratados como propriedade de controle

A taxonomia O-RAN é dominada por direto/indireto/implícito. Oscilação, *parameter flipping*, *ping-pong* e *action churn* aparecem como efeitos, mas raramente são operacionalizados como uma quarta dimensão experimental com:

$$\text{churn rate, } t_{\text{settle}}, \text{ overshoot, reversal count.}$$

A H-RDL pode formalizar “conflito temporal” como categoria operacional mensurável.

7.3 Lacuna 3: equilíbrio entre baixa latência e governança rica

PACIFISTA privilegia profiling; COMIX usa NDT; abordagens GNN/LLM privilegiam adaptação. A H-RDL busca um ponto diferente: **resolver casos frequentes e conhecidos com determinismo sub-ms**, escalando apenas conflitos complexos para módulos cognitivos. Essa arquitetura hierárquica pode ser defendida como *fast-path/slow-path conflict governance*.

7.4 Lacuna 4: cadeia causal e auditabilidade

A literatura de conflito frequentemente mede KPI antes/depois, mas a rastreabilidade de:

$$KPM(t_0) \rightarrow \text{proposal} \rightarrow \text{conflict} \rightarrow \text{decision} \rightarrow \text{E2SM-RC} \rightarrow \text{ACK} \rightarrow KPM(t_1)$$

pode diferenciar o XApp-RDL se cada transição for associada a IDs, timestamps e evidência reproduzível. Isso também aproxima o trabalho de requisitos de operação auditável em 6G AI-native.

7.5 Lacuna 5: preservação da independência multi-vendor

Team learning e *distillation* assumem acesso ou cooperação mais intensa entre modelos. Em ambientes comerciais, xApps podem ser caixas-pretas de fornecedores distintos. Uma camada RDL externa pode arbitrar *propostas* sem exigir re-treinamento nem exposição do modelo interno. Esse é um argumento forte de aplicabilidade.

8 Como posicionar o trabalho em relação aos principais concorrentes

8.1 Versus Adamczyk & Kliks CMF

O CMF é o ancestral arquitetural mais próximo. O XApp-RDL deve evitar alegar que “introduz” genericamente conflito direto/indireto/implícito. A contribuição deve ser formulada como:

- arbitragem hierárquica operacional;
- *Safety Guards* físicos desacoplados;
- conflito temporal/churn como dimensão experimental;
- cadeia causal E2 completa;
- avaliação multi-baseline com SLA, Jain, estabilidade e latência.

8.2 Versus QACM/game theory

A H-RDL pode usar Nash/barganha, mas não deve vender “game theory para conflito” como novidade. O diferencial é integrar a barganha a limites físicos, políticas de cooldown e execução E2 dentro de um fast-path determinístico.

8.3 Versus PACIFISTA

PACIFISTA é forte em profiling preventivo e severidade. A H-RDL é forte em runtime e enforcement. São complementares. Uma discussão madura deve dizer que PACIFISTA pode atuar *antes do deployment*, enquanto RDL governa ações *durante a execução*.

8.4 Versus COMIX

COMIX é a comparação mais importante para Energy-vs-QoS/power. A diferença a enfatizar é custo e modelo de segurança: COMIX usa NDT para avaliar alternativas; a H-RDL pode aplicar invariantes e arbitragem rápida no caminho crítico, reservando simulação/ML para escalonamento cognitivo.

8.5 Versus xApp Distillation

Distillation elimina conflitos fundindo conhecimento em um modelo. RDL mantém as xApps como entidades independentes. Isso é relevante para *multi-vendor*, atualizações independentes, certificação e rollback por aplicação.

8.6 Versus AI-native/LLM 2026

As abordagens de 2026 mostram a direção do campo, mas não invalidam a H-RDL: pelo contrário, aumentam a necessidade de *guard rails* determinísticos. Quanto mais sofisticado o raciocínio, mais valiosa se torna uma fronteira de atuação verificável antes do E2 Control.

9 Relação direta entre cada hipótese e a literatura

9.1 H1

Hipótese plausível e bem fundamentada. Team learning, QACM, PACIFISTA, CMF-OTIC, xApp Distillation e ORIGAMI convergem na evidência de que conflito não coordenado degrada desempenho e que mediação melhora QoS/estabilidade. A novidade não é “mitigação melhora SLA”, mas o **quanto**, sob quais cenários e com qual garantia de justiça.

9.2 H2

Hipótese relevante e menos saturada. A literatura fala em instabilidade e ping-pong, mas há espaço para uma contribuição quantitativa centrada em *Action Churn*, cooldown e tempo de acomodação. Recomenda-se tratar H2 como uma das contribuições principais, não apenas métrica secundária.

9.3 H3

Hipótese tecnicamente plausível. FlexRIC e medições recentes de xApps AI mostram que o caminho computacional pode ficar muito abaixo do limite temporal do Near-RT RIC. O artigo deve separar:

$$T_{\text{decision}}, \quad T_{\text{RIC}}, \quad T_{\text{E2 transport}}, \quad T_{\text{RAN effect}}, \quad T_{\text{loop}}.$$

Isso evita confundir “0,12 ms de decisão” com latência end-to-end da malha.

9.4 H4

Hipótese alinhada à fronteira 2026. Safe-RL e arquiteturas auditáveis indicam que otimização aprendida sem barreira de segurança é insuficiente. O resultado *UnsafeApplied* $\equiv 0$ deve ser acompanhado de *fault injection*: valores fora do domínio, NaN/Inf, TxPower impossível, overbooking de PRB e decisões adversariais.

10 Recomendações para fortalecer a seção de Trabalhos Relacionados do manuscrito

1. Organizar a literatura por **mecanismo de governança**, e não apenas cronologicamente: (i) cooperação; (ii) prioridade/CMF; (iii) game theory/QoS; (iv) profiling/grafos; (v) NDT/scheduler; (vi) distillation/AI-native.
2. Incluir PACIFISTA, QACM, Adamczyk–Kliks, COMIX, OTIC e xApp Distillation obrigatoriamente na tabela principal.
3. Separar **detecção** de **resolução**. Vários trabalhos detectam conflitos, mas usam mitigação simples; outros otimizam a resolução assumindo conflitos conhecidos.
4. Separar **segurança de ação** de **qualidade da decisão**. Uma ação pode ser subótima sem ser fisicamente insegura.
5. Não afirmar superioridade global sem reproduzir baselines sob o mesmo cenário. Usar termos como “complementa”, “difere”, “opera no fast-path” e “preserva independência”.
6. Reportar complexidade da arbitragem em função de número de xApps, propostas e parâmetros: $O(N)$, $O(N \log N)$ ou conforme a implementação.
7. Medir P50/P95/P99 de T_{decision} , não apenas média.
8. Criar ablação do *Safety Guard*: H-RDL completa versus H-RDL sem guard, especialmente em S7.
9. Criar ablação de cooldown/memória em S5 para provar causalmente H2.
10. Reproduzir pelo menos dois baselines externos: prioridade CMF e uma política QoS/game-theoretic simplificada; idealmente incluir scheduler ou QACM aproximado.

11 Síntese: originalidade defensável

A revisão não sustenta a tese de que o XApp-RDL seja o primeiro sistema a detectar ou mitigar conflitos entre xApps. Essa alegação seria incompatível com Adamczyk–Kliks, Team Learning, QACM, PACIFISTA e demais trabalhos.

A originalidade mais defensável é a **combinação**:

1. governança runtime multi-xAppno Near-RT RIC;
2. fast-path determinístico de baixa latência;
3. arbitragem de objetivos com métricas de SLA e justiça;
4. conflito temporal tratado explicitamente;
5. barreira de segurança determinística desacoplada do método de decisão;
6. evolução para slow-path cognitivo com KG/GNN/Safe-MAPPO;
7. rastreabilidade causal de proposta até efeito pós-E2.

Em outras palavras, o posicionamento científico mais forte não é “mais um algoritmo de conflict mitigation”, mas uma **arquitetura hierárquica de governança segura**: decisões simples e críticas são resolvidas por um mecanismo verificável e rápido; casos contextuais/ocultos são escalados para mecanismos cognitivos sem remover a barreira determinística final.

12 Conclusão

Entre 2020 e 2026, o tema evoluiu de “como executar IA em O-RAN” para “como governar múltiplas IAs e funções concorrentes”. O consenso da literatura é que a independência de xApps cria acoplamentos capazes de degradar QoS, induzir instabilidade e quebrar objetivos operacionais. O estado da arte de 2026 combina GNNs, Digital Twins, distillation, orquestração AI-native e agentes generativos, mas permanece aberta a questão de como conciliar adaptabilidade com garantias determinísticas e baixo overhead no caminho crítico.

Esse é o espaço mais promissor para o XApp-RDL-F1: uma camada de decisão e recursos que não substitui as xApps, mas governa suas ações, mede conflitos temporais, impõe invariantes físicos e cria uma trajetória evolutiva para Safe-MARL/6G sem sacrificar auditabilidade.

Referências

- [1] L. Bonati, S. D’Oro, M. Polese, S. Basagni, and T. Melodia, “Intelligence and learning in o-ran for data-driven nextg cellular networks,” *IEEE Communications Magazine*, vol. 59, no. 10, pp. 21–27, 2021.
- [2] P. E. I. Rivera, S. Mollahasani, and M. Erol-Kantarci, “Multi agent team learning in disaggregated virtualized open radio access networks (o-ran),” 2020.
- [3] R. Schmidt, M. Irazabal, and N. Nikaein, “Flexric: an sdk for next-generation sd-rans,” in *Proceedings of the 17th International Conference on emerging Networking EXperiments and Technologies (CoNEXT)*, 2021, pp. 411–425.
- [4] M. Polese, L. Bonati, S. D’Oro, S. Basagni, and T. Melodia, “Colo-ran: Developing machine learning-based xapps for open ran closed-loop control on programmable experimental platforms,” *IEEE Transactions on Mobile Computing*, vol. 22, no. 10, pp. 5787–5800, 2023.
- [5] L. Bonati, M. Polese, S. D’Oro, S. Basagni, and T. Melodia, “Openran gym: Ai/ml development, data collection, and testing for o-ran on pawr platforms,” *Computer Networks*, vol. 220, p. 109502, 2023.
- [6] M. Dryjański, Łukasz Kułacz, and A. Kliks, “Toward modular and flexible open ran implementations in 6g networks: Traffic steering use case and o-ran xapps,” *Sensors*, vol. 21, no. 24, p. 8173, 2021.
- [7] H. Zhang, H. Zhou, and M. Erol-Kantarci, “Team learning-based resource allocation for open radio access network (o-ran),” in *IEEE International Conference on Communications (ICC)*, 2022, pp. 4938–4943.
- [8] M. Kouchaki and V. Marojevic, “Actor-critic network for o-ran resource allocation: xapp design, deployment, and analysis,” in *IEEE Globecom Workshops*, 2022.
- [9] C. Adamczyk and A. Kliks, “Conflict mitigation framework and conflict detection in o-ran near-rt ric,” *IEEE Communications Magazine*, vol. 61, no. 12, pp. 199–205, 2023.
- [10] A. Wadud, F. Golpayegani, and N. Afraz, “Conflict management in the near-rt-ric of open ran: A game theoretic approach,” in *2023 IEEE iThings/GreenCom/CPSCoM/SmartData/Cybermatics*, 2023, pp. 479–486.
- [11] —, “Qacm: Qos-aware xapp conflict mitigation in open ran,” *IEEE Transactions on Green Communications and Networking*, vol. 8, no. 3, pp. 978–993, 2024.
- [12] P. B. del Prever, S. D’Oro, L. Bonati, M. Polese, M. Tsampazi, H. Lehmann, and T. Melodia, “Pacifista: Conflict evaluation and management in open ran,” *IEEE Transactions on Mobile Computing*, vol. 24, no. 10, pp. 10 590–10 605, 2025.
- [13] M. Corici, R. Modroiu, F. Eichhorn, E. Troudt, and T. Magedanz, “Towards efficient conflict mitigation in the converged 6g open ran control plane,” *Annals of Telecommunications*, vol. 79, pp. 621–631, 2024.
- [14] A. Zolghadr, J. F. Santos, L. A. DaSilva, and J. Kibilda, “Learning and reconstructing conflicts in o-ran: A graph neural network approach,” in *2025 IEEE Wireless Communications and Networking Conference (WCNC)*, 2025.

- [15] A. E. Giannopoulos, S. T. Spantideas, G. Levis, A. S. Kalafatelis, and P. Trakadas, “Comix: Generalized conflict management in o-ran xapps—architecture, workflow, and a power control case,” *IEEE Access*, vol. 13, pp. 116 684–116 700, 2025.
- [16] I. Cinemre and T. Mahmoodi, “xapp conflict mitigation with scheduler,” 2025.
- [17] A. Sultana, C. Adamczyk, M. R. Chowdhury, A. Kliks, and A. D. Silva, “Experimental evaluation of xapp conflict mitigation framework in o-ran: Insights from testbed deployment in otic,” in *IEEE INFOCOM Workshops*, 2025.
- [18] P. Sharma, S. Sun, S. Deshpande, A. Stavrou, and H. Wang, “Towards xapp conflict evaluation with explainable machine learning and causal inference in o-ran,” 2025.
- [19] H. Erdol, X. Wang, R. J. Piechocki, G. Oikonomou, and A. Parekh, “xapp distillation: Ai-based conflict mitigation in b5g o-ran,” *Computer Networks*, vol. 274, p. 111848, 2026.
- [20] A. Wadud, F. Golpayegani, and N. Afraz, “Ai-powered conflict management in open ran: Detection, classification, and mitigation,” *Computer Networks*, vol. 286, p. 112432, 2026.
- [21] M. A. Rahman, A. Duque, N. Chukhno, B. Niznik, M. Gramaglia, and A. Garcia-Saavedra, “Conflict mitigation of xapps and interoperability of o-ran components: The origami approach,” in *2026 Joint European Conference on Networks and Communications & 6G Summit (EuCNC/6G Summit)*, 2026, pp. 594–599.
- [22] S. Salmi, M. A. Ouameur, M. Bagaa, G. C. Alexandropoulos *et al.*, “Ai-native o-ran architectures for 6g: Toward real-time adaptation, conflict resolution, and efficient resource management,” *IEEE Transactions on Network and Service Management*, vol. 23, pp. 4110–4121, 2026.
- [23] C. Kurtulan, O. Kalinagac, E. Ozdemir, B. Gorkemli, G. Karakus, S. Aktas, and M. Basaran, “Ml-driven network orchestrator for 6g o-ran: Resolving multi-xapp conflicts in near-rt ric,” *ITU Journal on Future and Evolving Technologies*, vol. 7, no. 2, pp. 145–159, 2026.
- [24] D. C. Kwon and X. Zhang, “Open ran conflict agents: Detecting and mitigating xapp conflicts with generative agents,” in *IEEE INFOCOM 2026*, 2026, pp. 1–10.
- [25] L. Obiuevwi, K. J. Rehowicz, S. Jayarathna, S. H. Bouk, F. Afrin, C. N. Barati, N. Moghim, V. Nannou, M. E. Rahman, and S. Shetty, “Enabling real-time ai in o-ran: Deploying and measuring ai inside a near-rt ric xapp,” 2026.
- [26] A. Tuerxun and A. Nakao, “Safe ran slicing in o-ran: Minimizing sla violations via model-based reinforcement learning,” in *IEEE Consumer Communications and Networking Conference (CCNC)*, 2026.
- [27] S. A. Khowaja, K. Dev, and G. C. Alexandropoulos, “Z2-act: End-to-end verifiable agentic intent control for open 6g ran,” 2026.